

200+
并行评测任务

70%
人工评测工作量降低

30%
评测耗时缩短

25%
长任务成功率提升

个人简介

面向 Agent 产品的应届候选人，有 AI 产品与 Agent 评测实习经验。能将模糊的任务完成标准拆解为 Task / Trace / Evidence / Rubric / Judge 等可执行对象，并围绕轨迹证据、回归评测、失败标签和数据回流搭建迭代闭环。

核心经历

2024 - 至今 · 从 AI 机制到产品与评测闭环

2024 建立 Agent 视角

从 ReAct、Planning、Memory 和 Multi-Agent 的可运行实现理解行为机制。

2025 转向产品闭环

将生成能力映射为首次生成、二次编辑、局部修改和结果验收。

2025 沉淀评测系统

用结构化证据、自动检查与人工复核把 Agent 行为变成可测量系统。

DeepWisdom Agent Evaluation Harness · Agent 评测体系

核心共建

角色 面向多 Agent 与多模态生成场景，把模糊的完成标准转换为可复现、可追踪的评测对象。

动作 定义 Task、Dataset、Run、Trace、Evidence、Rubric、Judge、Report 与失败标签；用 JSON Schema 规范 10+ 维评分规则，并设计 Replay / Rollback / Retry / Edit 需求。

结果 自动化回归与抽样复核使人工评测工作量降低 70%；长任务成功率提升 25%，版本恢复时间缩短 60%。

FunloomAI · AI 游戏生成 SaaS

产品方案负责

角色 负责“自然语言到可玩原型”的产品架构，将 Agent 能力组织成可见、可编辑、可验证的用户流程。

动作 访谈 20+ 开发者与创作者，归纳不可控生成、修改断裂、本地编辑弱等问题；比较单模型、模板和多 Agent 方案，制定首次生成与二次编辑验收信号。

结果 优化注册、首次生成、编辑和发布路径，新用户 7 日留存从 23% 提升至 61%，支撑 30,000+ 注册用户与多款 TapTap 游戏上线。

all-agentic-architectures · Agent 架构开源实践

独立开发

角色 面向现代 Agent 架构建立可运行学习路径，用实例验证产品概念与工程机制。

动作 覆盖 Reflection、Tool Use、ReAct、Planning、Multi-Agent、PEV、Memory、Tree of Thoughts、dry-run harness 与自改进循环，组织为可运行 Notebook。

结果 将 LLM-as-a-Judge、轨迹证据和 verifier loop 贯穿实作，形成持续的 Agent 评测与架构公开知识库。

数字媒体数据集成与管理系统 · RAG 与数据产品

独立设计 / 著作权人

角色 针对图像、音频、文本与 3D 资产分散、来源难追溯和复用低效问题，独立定义系统。

动作 设计文件类型、来源、标签、项目归属、版权与更新历史的资源本体；规划 RAG 检索、证据链、使用语境摘要和素材包推荐流程。

结果 完成导入、标注、权利跟踪、检索、推荐和复用报告模块设计，获软件著作权 2025SR0148410。

代表性产出

8+ 诊断文档

支持提示词迭代、失败归因与 SFT 数据选择。

10+ 维 Rubric

覆盖完整性、准确性、一致性、指令遵循与格式稳定性。

4 类恢复机制

Replay、Rollback、Retry 与 Edit，配合快照、日志与阶段触发。

数字媒体数据集成与管理系统	独立设计媒体资源本体、RAG 检索与证据溯源流程，获软件著作权 2025SR0148410。	AI 工作流工具	开发 RSS 技术阅读、Markdown 到 X Article 排版与 AI 求职管道工具，连接信息摄取、发布和职位研究。
---------------	---	----------	--

持续输出 在 X @Potatoloogs 与微信公众号“[Ajar](#)”长期写作，聚焦 Agent 工具调用、规划、记忆、上下文工程和评测体系；代表主题包括“AI 评测系统”与“LLM 记忆架构比较”。

代表性技术写作

Agent 评测 · 记忆与上下文工程

评测体系	《AI 评测系统：从数据集到生产反馈闭环》，拆解 Task、Dataset、Run、Trace、Evidence、Rubric、Judge 与 Report。	记忆系统	《LLM 记忆系统技术分析》，比较 ChatGPT、Claude 与 Gemini 的记忆架构、上下文管理和产品取舍。
------	---	------	---

AI 产品判断

证据优先	恢复即产品	评测驱动迭代
Agent 结果不能只看最终文本；需同时保留 轨迹、中间证据与工具状态。	长任务不可避免地会失败；快照、回放和局部重试应从需求阶段设计。	把 badcase 反馈到提示词、Agent 策略和 SFT 数据，形成 可对比版本闭环。

核心能力

Agent 产品建模	能将任务、轨迹、证据、评分和报告拆解为 可实施产品对象。
评测与数据闭环	掌握 Rubric、LLM-as-a-Judge、回归评测、badcase 分析、人工复核与 SFT 数据筛选。
长任务可恢复性	能定义快照、结构化日志、上下文缓存和 Replay / Rollback / Retry / Edit 机制。
产品研究与协作	可完成用户访谈、PRD、验收指标、A/B 测试，并在产品与算法之间做 能力转译。
工具与实作	Python、JSON Schema、SQL、GitHub、Figma、Notion 与 飞书；能用 可运行原型 和 自动检查 加速产品验证。

奖项与认可

2025	挑战杯北京市一等奖
2025	中国国际大学生创新大赛北京赛区一等奖
2025	全国大学生电子商务“三创赛”省级一等奖
2024	北京邮电大学三等奖学金

教育背景

北京邮电大学	· 伦敦玛丽女王大学联合培养 · 数字媒体技术工学学士 · GPA 3.37/4.00	2023.09 - 2027.07
相关课程	Web 技术基础 97 · 数据科学数学基础 93 · Java 程序设计 91 · Design & Build Project I/II 90/90 · 生成式创意编程 89 · 游戏引擎基础 89	