



北京邮电大学

BEIJING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS

张靖远

☎ 18895466995 ✉ zjy888@bupt.edu.cn 📍 北京

🔗 z18895466995 📄 https://github.com/to-real

🎂 20岁 🧑 男 📏 180cm

🎓 在读 📅 模型策略产品实习生



🎓 教育经历

北京邮电大学 211 双一流

2023年09月 - 2027年06月

数字媒体技术 本科 全日制

北京

2023.09 - 2027.06 | 北京 | GPA: 3.50 / 4.0 | 获校级三等奖学金

竞赛: “挑战杯”北京市一等奖 | “三创赛”省级一等奖 | 中国国际大学生创新大赛北京市一等奖

📝 个人总结

北京邮电大学数字媒体技术本科, 专注 Agent Evaluation、Harness Engineering 与模型策略产品。具备从真实用户场景拆解模型能力 Gap、设计多维评测体系、并将 Badcase 归因反哺训练数据构建、推动策略迭代上线的完整闭环经验。深度使用 Claude Code、OpenClaw、Manus 等主流 Agent, 对其 Tool Use、Planning、长期记忆、Multi-Agent 协作机制与真实场景下的能力瓶颈有体系化认知。长期产出 AI / Agent 公开技术写作, 对文字质量与表达有较强敏感度。

💼 实习/工作经历

厦门深度赋智科技有限公司

2025年06月 - 2025年10月

AI 产品 / Agent Evaluation 实习生

深圳

(1) Agent Evaluation Harness 评测闭环设计 | 评测效率 +30%

情境: 面向多智能体任务与图像生成 / 多模态评估场景, 参与构建 Agent Evaluation Harness, 串联 Prompt 输入、模型 / Agent 执行、结果评测、人工复核与数据反馈流程, 提升评测效率、准确性与可复现性。

行动: 将评估流程拆解为任务样本、执行轨迹、结果证据、评分规则、失败标签与数据反馈等关键环节; 用 Python 编写自动化检测脚本, 完成图像完整性检测与语义一致性评估; 优化批量评测流程, 引入异步执行与任务队列机制, 支持多任务并行评估。

结果: 评估任务运行时间下降 30%, 支持并行处理 200+ 任务实例, 为模型策略迭代提供稳定的自动化评测基础; 参与功能测试与上线验证, 推动评测结果沉淀为后续 Prompt 优化、失败样本复盘与策略调整依据。

(2) Prompt 评估 Pipeline 与 Rubric 设计 | 人工评测工作量 -70%

情境: 参与设计「Prompt 输入 → 生成执行 → 结果评测 → 数据反馈」评估链路, 为算法迭代提供量化反馈, 并沉淀可复用的评测规则与错误分类体系。

行动: 用 JSON Schema 定义评测规则, 建立覆盖完整率、准确性、一致性、语义质量、指令遵循、格式稳定性等 10+ 维度的评分体系; 编写测试脚本进行批量回归测试, 结合人工复核机制提升评测可信度; 梳理生成失败、语义偏差、上下文不一致、格式错误、任务未完成等错误类型。

结果: 人工评测工作量减少 70%, 输出问题诊断文档 8+ 篇, 帮助算法团队快速定位生成失败、语义偏差与一致性不足等核心问题; 沉淀可复用 Rubric 与失败标签, 为后续评测集扩展、Badcase 归因与高质量 SFT 数据筛选/构建提供依据, 形成「评测 → 归因 → 训练数据反哺」闭环。

(3) 多 Agent 任务生命周期与失败恢复机制设计 | 成功率 +25%

情境: 针对多智能体长流程任务中跨 session 记忆连续性差、多工具调度不可靠、状态不可追踪、失败难复现等问题, 设计 Replay / Rollback / Retry / Edit 机制, 提升任务执行的可见性、可调试性与可恢复性。

行动: 设计多 Agent 协作轨迹回放系统, 通过状态快照与结构化日志记录执行过程; 推动状态版本管理与上下文缓存机制建设; 设

计按执行阶段触发的智能重试逻辑，实现任务参数与 Prompt 的可视化编辑接口；参与 PRD 撰写、测试验证与上线监控，协调算法、前端、后端解决依赖耦合问题 5+。

结果：版本恢复时间缩短 60%，任务执行成功率提升 25%，问题修复周期缩短 40%；建立触发频率、成功率、回放占比、重试占比等功能监控指标，形成从功能上线、数据反馈到策略调整的闭环。

FunloomAI——AI驱动的游戏开发SaaS产品 2025年02月 - 2025年06月

AI 产品经理实习生

(1) AI 游戏创作 Agent 场景定义与模型能力 Gap 拆解

情境：面向「自然语言 → 游戏原型」的 AI 创作场景，参与平台产品设计。场景涉及需求理解、任务规划、代码生成、素材生成、多轮修改与结果验证，具备复杂创作型 Agent 的典型特征。

行动：通过 20+ 开发者与创作者访谈，梳理上手门槛高、生成结果不可控、修改链路不连续、迭代成本高等核心痛点；将用户反馈拆解为意图理解、任务规划、上下文继承、局部编辑、结果验证等模型能力 Gap；对比单一大模型、模板化生成、多 Agent 协作三类方案，评估其在稳定性、可控性、成本与扩展性上的取舍。

结果：输出用户访谈纪要、核心痛点归因与功能优先级建议，梳理首次生成、二次编辑、局部修改、结果预览等关键模块的优化方向，沉淀为模型能力需求与评测 / 数据方案的输入，为后续产品迭代和 Agent workflow 设计提供依据。

(2) 创作转化路径优化与数据验证

情境：产品早期增长阶段，需降低用户从注册到首次生成、编辑、发布的使用门槛，验证 AI 游戏创作平台的核心价值与用户留存能力。

行动：拆解用户首次生成、结果编辑、二次修改与发布转化路径，通过 A/B 测试优化关键流程；围绕用户首次成功体验调整功能入口、引导路径与结果反馈方式，提升用户对生成结果的可理解性、可编辑性与继续创作意愿。

结果：新用户 7 日留存率从 23% → 61%，累计注册用户 3W+；项目正式发布，多款游戏上线 TapTap，并获千万元级别天使轮融资。

🔗 AI 产品研究与架构

2024年03月 - 至今

- 系统研究 Agent 产品中的 Tool Use、Planning、Memory、Context Engineering 与 Multi-Agent 协作机制，关注长流程任务中的状态丢失、任务漂移、工具调用失败与可恢复性问题。
- 拆解 Claude Code、OpenClaw、Manus、Deep Research 等 Agent 产品，分析其在工具调用、任务分解、记忆管理、权限控制与失败恢复上的产品取舍；对主流 Agent Benchmark（如 SWE-bench / GAIA / τ -bench 等）与真实用户场景下的能力瓶颈有体系化认知，能将竞品观察转化为可落地的模型优化方向。
- 围绕 Agent Evaluation Harness 建立分析框架，理解 Task / Dataset / Run / Trace / Evidence / Rubric / Judge / Report 在模型能力评估与策略迭代中的作用。
- 将 Agent / Context Engineering / 模型评测相关研究持续转化为公开技术长文与产品分析内容，用外部反馈验证判断——长期写作也带来对文字质量与表达的敏感度。

🔗 技能

- AI / Agent：LLM 架构理解 | Harness Engineering | Prompt Engineering | Tool Use / Planning / Memory / Multi-Agent 机制
- 评测与数据：模型评测体系设计 | Rubric / 评分标准设计 | 自动化 + 人工评估 | Badcase 归因与数据反哺 | SFT/RL 数据生产标准
- 研究方法论：Competitive Research | 技术逆向分析 | Research-to-Article workflow
- 产品能力：用户研究 | 数据分析（Python / SQL）| 原型设计（Figma / Stitch）
- 协作工具：Notion / 飞书
- 语言：英语（CET-6/雅思 7）